

科技部

113 年度大專學生專題研究計畫

基於生成式對抗網路預測岸線變遷-以旗津海岸為例

臺南應用科技大學

資訊管理學系三年級

研究學生：施坤政

指導教授：楊正宏 教授

中華民國 113 年 2 月

(一) 摘要

本研究聚焦於旗津海岸，研究範圍自北至高雄港一港口，南至高雄港二港口，旨在深入探討海岸變遷以及現有海岸保護工程的成效[圖 1-1]。旗津地處高雄市西南邊陲，為一座小島，地質主要由海流沖積形成的潟湖。儘管自 2009 年起實施七億元的海岸線保護工程，總長 3.6 公里，涵蓋旗津海水浴場至風車公園，包含十一座潛堤等工法，形成第一道防線，海水侵蝕仍長期影響海岸線，每年平均退縮約五至十公尺，導致沿岸設施地基掏空。政府的海岸保護工程於 2013 年完工，其成效需要長期觀察。

本研究擬透過分析 2003-2023 年的旗津海岸衛星影像，並運用機器學習演算法，包括 Convolutional Neural Network(CNN) 提取影像特徵、Long Short-Term Memory(LSTM) 提取 CNN 的輸出找尋時序特徵，以及 Generative Adversarial Network(GAN) 直觀的模擬海岸變化，特別關注灘線的變化。藉此，評估現行海岸防護工法的實效性，並與相似研究方法如 Canny 法、改進 U-Net 網絡分析、灘線平移修正法(OSM)、海岸數化分析系統(DSAS)進行比較，最終使用 Inception Score(IS)、Frechet Inception Distance(FID)、Perceptual Similarity(PSNR)和 SSIM 等指標評估模型性能。

旗津海岸作為高雄地區的重要資產，對台灣經濟和國土有著重大影響。本研究期望透過對旗津海岸灘線變遷的深入研究，為台灣的國土維護提供有價值的貢獻。

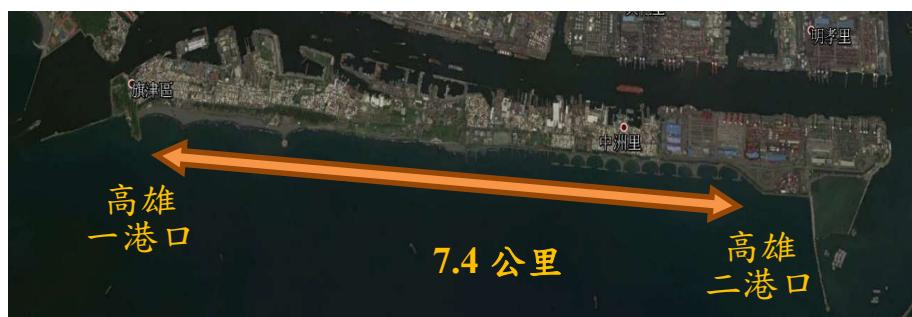


圖 1-1 高雄旗津港示意圖

(二) 研究動機與研究問題

研究動機

近年來，海岸侵蝕分析研究除了使用實測資料進行現況分析外，也倚賴模擬軟體及長時間衛星影像資料，以補足現地資料的不足。高雄旗津海岸面臨嚴重侵蝕，海岸線不斷後退。測量海岸線工程中，現場觀測複雜且成本高。同時，由於現場的氣候條件複雜，還要考慮風和科氏力作用等一系列問題，尤其是在大風大浪的情況下很難再進行現場觀測。若能藉由衛星影像圖來分析海岸地形變遷，將有助於了解漂沙的時間尺度和探討現今旗津海岸防護工法的成效。

[1,2,3]。使用深度學習網路 CNN 與 LSTM 提取出歷年海岸線的變化特徵，這兩種神經網路分別負責捕捉圖像的空間特徵和時間序列的演變趨勢[4]，CNN 與 LSTM 的輸出特徵則成為 GAN 的輸入數據。在不考慮人為及自然災害等因素的影響，只針對海岸線歷年變化非常適合使用 GAN 模擬預測。

研究問題

GAN 預測海岸線的訓練數據都是基於 CNN 和 LSTM 兩者所產生的圖片特徵去進行訓練。因參考徐等人[5]的文獻而啟發本研究將 GAN 與 CNN-LSTM 訓練分開執行。有以下幾點說明：

1. **避免生成器主導：** 生成器具有更多的參數，同時訓練可能導致 GAN 生成器主導整個訓練過程，不利於 CNN-LSTM 學習捕捉時空序列的長期依賴性。
2. **訓練目標區分：** 將它們分開訓練有助於明確訓練目標。生成器的目標是成逼真的圖像，而不是發現影像特徵及序列的演變規律。這樣可以確保生成器專注於其生成任務，而不是與兩者競爭。
3. **處理圖像冗餘性：** 直接使用圖像訓練 CNN-LSTM 可能面臨冗餘性挑戰，因為圖像中可能包含大量冗餘信息。這使得兩者難以有效地學習到影像特徵與序列的演變規律。將 GAN 生成器和兩者分開訓練可以更好地處理這種情況。值得注意的是，天災和人災可能引入不穩定性因素，例如，颱風、洪水或人為工程活動可能導致海岸地形的急劇變化，這些變化可能難以預測且對模型的穩定性造成挑戰。在考慮這些不確定性因素時，模型的靈活適應能力和預測準確性變得尤為重要。

(三) 文獻回顧與探討

過去的研究中，GAN 技術已被廣泛運用於多個領域，如生成圖片、轉換圖片顏色以及改變物體型態等[6,7]。在海岸地形變化的領域，使用 GAN 技術的先例主要著重在模擬海岸線影像的變化，以提供更真實的未來景象。討論過去在預測海岸線方法的不同，以先前的研究為例，如下：

張等人[8] 使用衛星影像研究外傘頂洲的灘線變遷。方法包括 IHS 轉換法、NDWI、影像強化、形態學和 Canny 法分析灘線變化。修正 NAO99b 潮位模型解決潮汐資料缺失。陸地逐年增加被侵蝕，夏季增加、冬季減少。根據 2009-2015 的速率預測，外傘頂洲陸地預計 2060 年完全低於平均潮位沉入沙洲。

林[9]利用 Google Earth 獲取 2002-2017 年旗津海岸線衛星圖，使用 Matlab 工具分析灘線變化，以評估不同海岸防護工法的效果，提出一有效快速的方法進行比較分析。研究關注離岸堤、離岸潛堤、人工岬灣等海岸保護工法對灘線變化的影響。

施等人[10]利用 SONY EVI-D70 攝影機，拍攝高雄西子灣海岸影像(640×480 pixels)。透過攝影機內、外部參數校正、全景影像拼接與主動輪廓模式等方法，萃取西子灣海岸逐時之影像灘面與水面交界線，再運用潮位修正與潮位配合 5 種波揚(wave setup)推估方法，分析西子灣影像海岸線，並與即時動態衛星定位系統所檢測海岸線結果進行比對，探討波揚修正公式應用於海岸線影像辨識分析之適用性。

與 Canny 法、Matlab 工具、波揚修正方法，這些分析灘線方法比較，前兩者基於套疊不同時間的灘線影像作為主要分析法，波揚修正方法則是調整海岸線位置的方法，考慮波浪引起的水位變化。目的是更精確反映實際陸地位置，而本研究的方法更傾向於使用 CNN 完整分析灘線影像細節，LSTM 分析和預測灘線時間序列特徵，最後使用 GAN 生成可能的海岸線樣態。

(四) 研究方法及步驟

一、研究步驟

本研究計畫預計探討旗津海岸的灘線變化，各階段步驟如下：

1. 收集岸線衛星雲圖資料，使用 CNN 對萃取的影像進行加工處理。
2. 使用 CNN 提取影像的空間特徵，並應用 LSTM 提取時間序列特徵。
3. 整合兩者輸出特徵，輸入 GAN 建模，預測旗津海岸線未來變遷。
4. 測試不同方法之準確率。
5. 針對本研究所使用的模型進行評估。

圖 4-1 為本研究計畫流程圖。

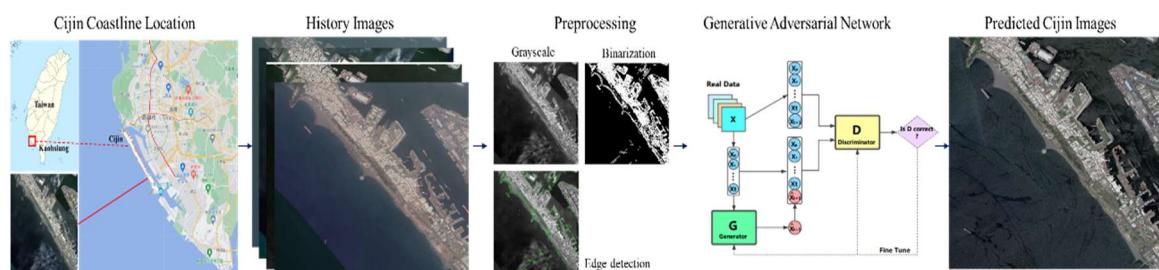


圖 4-1 計畫流程圖

(一) 收集岸線衛星雲圖資料，使用 CNN 對萃取的影像進行加工處理

在本研究中，以旗津海岸線為對象，採用全面而系統的方法進行了深入分析。首先，使用 Google earth 進行旗津海岸影像數據收集，獲取了高解析度的 2003-2023 年旗津海岸衛星影像數據，為了精確研究，引入了卷積神經網路 (CNN) 對影像進行了裁剪和預處理(圖 4-1 中 Preprocessing 階段)，同時進行了對比度和亮度的調整，並去除了潛在的雜訊[11]。透過後處理步驟，進一步優化了提

取的海岸線結果，包括去除不需要的部分並填充可能存在的缺失區域，確保了最終呈現的海岸線圖像既準確又整潔。

(二) 使用 CNN 提取影像的空間特徵，並應用 LSTM 提取時間序列特徵。

1. Convolutional neural network

卷積神經網路(Convolutional neural network, CNN)由一個或多個卷積層和頂端的全連通層(對應經典的神經網路)組成，同時也包括關聯權重和池化層(pooling layer)。這一結構使得卷積神經網路能夠利用輸入資料的二維結構。與其他深度學習結構相比，卷積神經網路在圖像和語音辨識方面能夠給出更好的結果。CNN中採用共享權重和局部連接來充分利用影像訊號等二維輸入資料結構。此操作使用極少量的參數，既簡化了訓練過程，又加快了網路速度。這與視覺皮層細胞中的情況相同，這一模型也可以使用反向傳播演算法進行訓練。相比較其他深度、前饋神經網路，卷積神經網路需要考量的參數更少，使之成為一種頗具吸引力的深度學習結構。架構圖如圖 4-2。

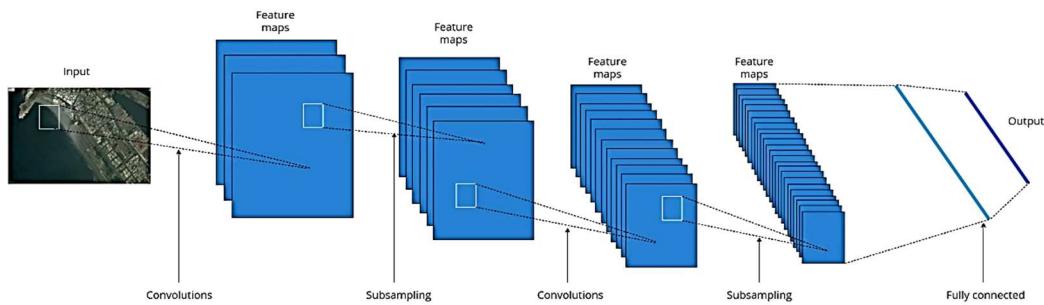


圖 4-2 CNN 架構圖

本研究目標是通過卷積神經網路(CNN)結構，將旗津海岸歷年衛星圖轉換為低維度的潛在向量表示，即 $Z=f(X)$ ，其中 X 表示原始複雜的衛星圖像， Z 為相應的潛在向量。然而，在這樣的轉換過程中，我們面臨著一個重要的問題，即如何確保生成的潛在向量 Z 能夠充分表達旗津海岸地形變遷的多樣性和變化。這個問題可用優化來形式化表示，即最小化原始圖像 X 與重建圖像 X' 之間的重建損失，同時保持潛在向量 Z 的信息充足。這可以用以下的公式表示：

$$\text{Minimize } L_{\text{recon}}(X, X') + \lambda L_{\text{info}}(Z) \quad (1)$$

Minimize 指的是我們的目標是將一個特定的函數最小化，這個函數稱為總體損失函數(Total Loss Function)，其中， L_{recon} 是重建損失函數，衡量原始圖像 X 與經編碼器解碼後的圖像 X' 之間的差異。 L_{info} 是信息保持損失函數，確保潛在向量 Z 中包含足夠的原始圖像信息。 λ 是調整參數，用於平衡這兩個損失。為了解決這個問題，我們需要改進編碼器網路的結構，以確保 Z 具有足夠的表達能力，同時維持 X 的重建準確性。這涉及調整卷積層數量、神經元數

目、激活函數等超參數，以最大程度地保留有價值的特徵。

2. Long Short-Term Memory

LSTM，全名為 Long Short-Term Memory，是一種循環神經網路（RNN）的變體，由 Sepp Hochreiter 和 Jürgen Schmidhuber 於 1997 年提出。其主要目標是解決傳統 RNN 在處理長序列時容易出現的梯度消失和梯度爆炸等問題。

LSTM 引入了遺忘門、輸入門和輸出門的概念，這三種門控制著信息的流動，使得模型能夠更有效地捕捉和記憶長期依賴性。遺忘門決定了前一個時間步的記憶是否被保留，輸入門則控制著新的信息進入記憶單元的程度，而輸出門則調節著記憶單元的輸出。公式分別表示：

$$\text{遺忘門 (Forget Gate)} : \quad ft = \sigma(Wf \cdot [ht - 1, xt] + bf) \quad (2)$$

$$\text{輸入門 (Input Gate)} : \quad it = \sigma(Wi \cdot [ht - 1, xt] + bi) \quad (3)$$

$$C_{\sim t} = \tanh(WC \cdot [ht - 1, xt] + bC) \quad (4)$$

$$\text{更新記憶單元 (Update Memory Cell)} : \quad Ct = ft \cdot Ct - 1 + it \cdot C_{\sim t} \quad (5)$$

$$\text{輸出門 (Output Gate)} : \quad ot = \sigma(Wo \cdot [ht - 1, xt] + bo) \quad (6)$$

$$\text{最終輸出和隱藏狀態} : \quad ht = ot \cdot \tanh(Ct) \quad (7)$$

ft 是遺忘門的輸出， it 是輸入門的輸出， $C_{\sim t}$ 是更新的記憶單元的候選值， Ct 是最終的記憶單元狀態， ot 是輸出門的輸出， ht 是最終的隱藏狀態。 σ 是 sigmoid 函數， \tanh 是雙曲正切函數， Wf, Wi, WC, Wo 是權重矩陣， bf, bi, bC, bo 是偏差項。 $[ht - 1, xt]$ 表示將上一時刻的隱藏狀態 $ht - 1$ 和當前的輸入 xt 串聯在一起。

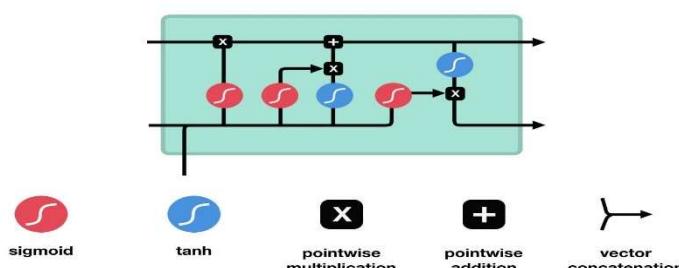


圖 4-3 LSTM 架構圖

依序講解 圖 4-3 LSTM 架構：

激活函數：圖中有三個紅色的圓圈，分別標記為“sigmoid”和“tanh”。

"Sigmoid" 就像衛星圖上的一個過濾器，決定是否保留某些信息或遺忘它，就像選擇性地捕捉或模糊某些區域的細節。

"Tanh" 則好比另一個過濾器，專門計算並調整新的信息，就像衛星圖上一個特定區域的強度或亮度。

數學運算：用黑色的線條連接了這些圓圈，表示數學運算的過程。

點對點的乘法 ("x") 和點對點的加法 ("+") 可能了權重和運算，就像在衛

星圖上進行各種數學運算以獲得新的資訊。

最終輸出：箭頭指向右側，表示最終的輸出是通過向量（Vector Concatenation）連接獲得的。

(三)整合兩者輸出特徵，輸入 GAN 建模，預測旗津海岸線未來變遷

1. Generative Adversarial Networks

生成式對抗網路(Generative adversarial networks, GAN)由 Yann LeCun 所提出，GAN 由兩個模型組成：生成器和判別器。這兩個模型通常使用神經網路來實現，但也可以使用任何形式的將資料從一個空間映射到另一個空間的可微分系統來實現，生成器嘗試捕獲真實範例的分佈並產生新的資料範例。鑑別器通常是一個二元分類器，用於盡可能準確地將生成的範例與真實的範例區分開。GAN 的最佳化是一個極小極大最佳化問題。最佳化終止於設定點，該設定點形成相對於生成器的最小值和相對於鑑別器的最大值，我們可以定義我們的價值的最佳化函數 $V(G,D)$ 如下式(8):

$$\min_G \max_D V(D, G) = E[\log D(x_{real})] + E[\log (1 - D(x_{fake}))] \quad (8)$$

我們定義生成器損失 G_{loss} 和鑑別器損失 D_{loss} 來最佳化價值函數。特別是，我們將均方誤差 (MSE) 與經典 GAN 的生成器損失結合如下：

$$D_{loss} = (1/m) \sum_{i=1}^m \log D(X_{real}^i) - (1/m) \sum_{i=1}^m \log (1 - D(X_{fake}^i)) \quad (9)$$

$$g_{MSE} = (1/m) \sum_{i=1}^m (\hat{x}_{t+1}^i - x_{t+1}^i)^2 \quad (10)$$

$$g_{loss} = (1/m) \sum_{i=1}^m \log (1 - D(X_{fake}^i)) \quad (11)$$

$$G_{loss} = \lambda_1 g_{MSE} + \lambda_2 g_{loss} \quad (12)$$

損失函數 G_{loss} 由 g_{MSE} 和 G_{loss} 組成，分別為 λ_1 和 λ_2 。 λ_1 和 λ_2 是超參數，圖 4-4 顯示了我們的 GAN 的架構。

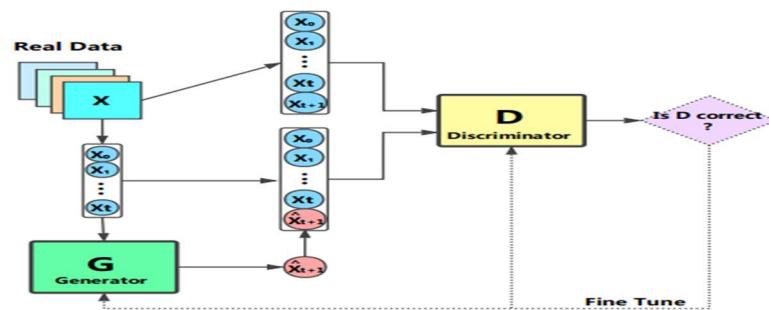


圖 4-4 GAN 架構

Dropout

類神經網路訓練中，防止過擬合是關鍵[12]，Srivastava 提出了一種在訓練中防止過擬合的方法(Srivastava, Hinton, Krizhevsky, Sutskever, & Salakhutdinov, 2014)，在神經網路層與層之間的訓練過程中，神經元以一定的機率從網路中隨

機丟棄，如圖 4-5 所示。

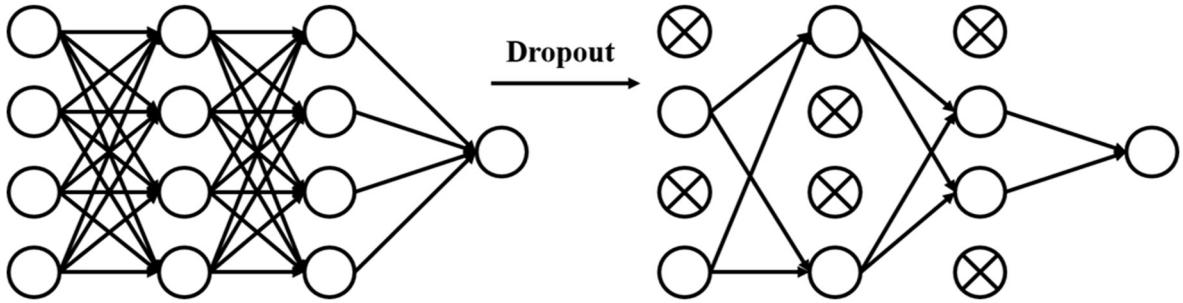


圖 4-5 Dropout 示意圖

(四)測試不同方法之準確率

需提升海岸變化預測的準確度，本研究會獲取不同的方法。將以海岸變化預測結果來探討方法上的誤差率並視覺化評估結果供日後對比(圖 4-7)，數據會利用常用的二元分類模型中(圖 4-6)，預測結果與實際結果結合產生四個元素，即真陽性、假陽性、真陰性和假陰性，分別以 TP、FP、TN 和 FN 表示：

Actual class \ Predicted		Positive	Negative
Positive	TP		FP
Negative	FN		TN

圖 4-6 混淆矩陣

透過這四種分類情況得到不同的效能指標來評估模型，包含：召回率(Recall)、精確率(Precision, F1-score)、準確率(Accuracy)、均方根誤差(Root-Mean-Square Error, RMSE)。

主要利用文獻及期刊上常見的海岸預測方法進行比較。如:Canny 法套疊影像進行預測[13]、U-Net 時間序列預測[14]、灘線平移修正法(one-line shifting method, OSM)[15]、海岸數化分析系統(DSAS)[16]。

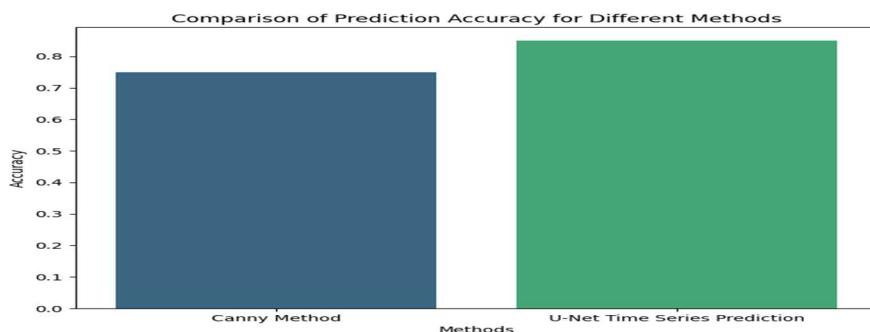


圖 4-7 評估結果示意圖

(五) 針對本研究所使用的模型進行評估

評估指標(Criteria)

針對CNN進行岸線邊緣偵測，使用標準評估模型的性能，即準確性(Accuracy)、精確性(Precision)、敏感性(Sensitivity)、特異性(Specificity)。另外增加IoU(Intersection over Union)及Dice係數(Dice Coefficient)相關方程式如下：

$$Specificity = TNR \quad (13)$$

$$Sensitivity = TPR \quad (14)$$

$$Precision = \frac{TP}{TP + FP} \quad (15)$$

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \quad (16)$$

$$IoU = \frac{\text{Area of Overlap}}{\text{Area of Union}} \quad (17)$$

$$Dice = \frac{2TP}{FN + 2TP + FP} \quad (18)$$

針對LSTM進行岸線歷年序列預測，使用常用的指標包括均方根誤差(Root Mean Squared Error, RMSE)和平均絕對誤差(Mean Absolute Error, MAE)。以下是這兩種評估指標的公式：

$$\text{均方根誤差 (RMSE)} : RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (19)$$

$$\text{平均絕對誤差 (MAE)} : MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (20)$$

RMSE與MAE的n是樣本數， \hat{y}_i 是預測值， y_i 是實際值。

針對GAN進行岸線預測，使用以下三種評估指標，分別是Inception Score(IS)、Frechet Inception Distance(FID)以及Perceptual Similarity(PSNR和SSIM)。

$$IS(G) = \exp(\mathbb{E}_{\mathbf{x} \sim p_g} D_{KL}(p(y | \mathbf{x}) \| p(y))) \quad (21)$$

$$FID = \|\mu_{real} - \mu_{fake}\|^2_2 + Tr(\Sigma_{real} + \Sigma_{fake} - 2(\Sigma_{real} \Sigma_{fake})^{1/2}) \quad (22)$$

μ_{real} 和 μ_{fake} 分別是真實影像和生成影像的特徵向量的平均值。

Σ_{real} 和 Σ_{fake} 分別是真實影像和生成影像的特徵向量的協方差矩陣。

Tr(\cdot)表示矩陣的跡。

$$PSNR = 10 \log_{10} \left(\frac{MAX^2}{MSE} \right) \quad (23)$$

其中，MAX是圖片像素的最大機率值，MSE是均方誤差。

$$SSIM = (L(x, y) \times C(x, y) \times S(x, y))^{\alpha} \quad (24)$$

其中， $(L(x,y)$ 衡量亮度相似性， $C(x,y)$ 衡量對比度相似性， $S(x,y)$ 衡量結構相似性， α 是一個可供調整的參數。

（五）預期結果

- (1) 透過 CNN 和 LSTM 的結合，能夠更全面地捕捉海岸變化的空間和時間特徵，提高模型對複雜變化的敏感性。
- (2) 通過模型預測的地形變引入 GAN 使模型能夠生成更真實、符合實際海岸變化的圖像，有助於提高模擬的準確性，使生成的影像更貼近實際情況。
- (3) 掌握不同的方法對於岸線分析的優缺點，並進行探討，以提供更準確的海岸分析方法及應用方式。
- (4) 分析所提出的 CNN-LSTM 演算法對海岸線分析所帶來的績效。
- (5) 評估生成預測影像的 GAN 演算法，以 IS、FID 以及 PSNR 和 SSIM 指標探討實驗結果。

（六）需要指導教授指導內容

1. 資料集解析及探討
2. 深度學習演算法之理論探討與技術分析
3. 實驗結果中 GAN 效果的分析
4. Python 程式語言基礎概念
5. Tensorflow 架構之應用
6. Keras 架構之應用
7. 海事資訊相關專業知識
8. 計畫方向擬定及計劃書內容撰寫
9. 實驗結果分析與討論
10. 計畫進度掌握與投稿時程控管
11. 期刊投稿內容之修訂建議

（七）參考文獻

- [1] 高雄市政府工務局，「旗津區海岸線保護工程」
<https://ncd.kcg.gov.tw/FileDownLoad/FileUpload/20190528192942821711.pdf>。
- [2] 財團法人中華顧問工程司，「海岸環境營造趨勢—以高雄市旗津海岸為例」
<https://www.ceci.org.tw/Upload/Download/CB57BE45-6670-417A-9C7B-49C28BF347D3.pdf>。
- [3] 高雄市政府工務局(2009)，旗津區海岸線保護工程(潛堤)，初步設計報告書。
- [4] 洪嘉昌，以相似性融合特徵與 CNN-LSTM 神經網路模型預測軸承剩餘使用

壽命，第 46-59 頁，(2023)。

- [5] Zhan Xu. Jun Du. Jingjing Wang. Chunxiao Jiang.& Yong Ren. "Satellite Image Prediction Relying on GAN and LSTM Neural Networks."Key Laboratory of EDA, Research Institute of Tsinghua University in Shenzhen, 518057, China,2019.
- [6] 李家瑋，「基於C-RNN-GAN神經網路的股票價格趨勢預測模型之研究-以美國股票市場為例」，輔仁大學，第23-27頁，(2020)。
- [7] 饒志鴻，以循環一致性生成對抗網路實現 圖像轉換之研究，第9-12頁，(2018)。
- [8] 張憲國、賴羿齊、陳蔚璋。應用衛星影像的水線辨識於外傘頂洲的灘線變遷，第244-252頁，(2017)。
- [9] 林忻緯，「應用Google Earth影像探討旗津海岸變遷之研究」，國立高雄海洋科技大學碩士論文，第 43-50頁，(2017)。
- [10] 施冠足、呂珍謀、郭晉安、簡仲和，「監視影像配合波揚修正公式應用於灘線辨識分析之研究—以高雄西子灣為例」，第三十七屆海洋工程研討會，台中，第 611-616 頁，(2015)。
- [11] Sadrizadeh S. Otroshi-Shahreza H. Marvasti F. "Impulsive Noise Removal via Blind CNN Enhanced by Iterative Post-processing." Signal Processing, 192, 108378. ISSN: 0165-1684. DOI: 10.1016/j.sigpro.2021.108378, 2022.
- [12] Srivastava N. Hinton G. Krizhevsky A. Sutskever I. & Salakhutdinov R. "Dropout: A Simple Way to Prevent Neural Networks from Overfitting" Journal of Machine Learning Research, Vol. 15, pp.1929-1958, 2014.
- [13] IEEE Transactions on Pattern Analysis and Machine Intelligence (Volume: PAMI-8) pp.679-698,1986.
- [14] WANG Rui, DING Dong, LI Guang-xue, REN Xin, HAN Hui-hui. Coastline extraction method based on an improved U-Net network[J]. Marina Sciences, 46(5): pp.54-64,2022.
- [15] 陳蔚璋，衛星影像的灘線辨識及其應用至灘線變遷之研究，第 28-35 頁，(2010)。
- [16] Nguyen An Thinh and Luc Hens, "A Digital Shoreline Analysis System (DSAS) Applied on Mangrove Shoreline Changes along the Giao Thuy Coastal area (Nam Dinh, Vietnam) during 2005-2014," Vietnam Journal of Earth Sciences, vol. 39, no.1 , DOI: 10.15625/0866-7187/39/1/9231. pp. 87-96, 2017.
- [17] (圖 4-3 LSTM 架構圖) Kuo, S. "Introduction to LSTM and GRU." Programming with Data.Available,2021. URL:<https://medium.com/>
- [18] (圖 4-4 GAN 架構) Zehui Wu,"Stock Market Prediction Using GAN", 2022.URL:<https://medium.com/>